

W I R D K I T E U R E R ?

Subventionen, Markt & Politik

Wer zahlt heute? Wer zahlt morgen?

\$1,35 verlorene Dollar pro \$1 Umsatz bei OpenAI

\$700 Mrd. Big-Tech-Capex in KI-Infrastruktur 2026

25 % Trump-Tarif auf KI-Chips, EU-Sovereignty-Push

Das große Paradox

KI war noch nie so billig. Und noch nie so teuer.



Für dich: scheinbar billig

ChatGPT Plus

\$20 / Monat – seit Februar 2023 unverändert

Claude Pro

\$20 / Monat – unbegrenzt Sonnet 4.6

Gratis-Tier ChatGPT

900 Mio. Nutzer wöchentlich – 94,5 % zahlen NICHTS

Inferenz-Kosten

Pro Antwort fallen technisch ~5-10x pro Jahr (Gartner)



Für die Anbieter: ruinös

OpenAI 2026

\$24 Mrd. Umsatz – aber \$14 Mrd. Verlust erwartet

Claude Code Power-User

Ein \$200-Abo kann bis zu \$5.000 Compute kosten

OpenAI bis 2028

Kumuliert \$44 Mrd. Verlust – Profit erst ab 2029

Compute-Commitments

OpenAI: über \$1 Billion zugesagt für Infrastruktur

Die Zahlen, die alles erklären

Was OpenAI, Anthropic & Co. wirklich kostet

\$1,35

verliert OpenAI pro \$1 Umsatz – jede Antwort kostet mehr als sie einbringt

\$700 Mrd.

Big-Tech-Ausgaben für KI-Infrastruktur 2026 – fast doppelt so viel wie 2025

\$5.000


Compute kann ein einziger \$200-Abonnent von Claude Code monatlich verursachen

5,5 %

der 900 Mio. ChatGPT-Nutzer zahlen wirklich – der Rest wird vom Investor finanziert

Wie Subventionen funktionieren

Du bekommst keinen Service – du bekommst eine Demo, finanziert von Investoren



Hast du das schon mal gesehen?

Amazon machte 9 Jahre lang Verluste, bis es seine Position dominant hatte. **Uber** verbrannte \$30 Mrd., bevor 2023 der erste Gewinn kam.

Beide Tricks: Erst billig anbieten und Konkurrenz verdrängen – dann Preise nach Lock-In erhöhen. Das ist die Vorlage für KI.

Warum ist KI so verdammt teuer?

Die echten Kostentreiber – kurz erklärt

GPUs

Eine einzige Nvidia H200 kostet ca. \$30.000. OpenAI braucht hunderttausende davon. Anthropic hatte Ende 2025 1,4 GW Rechenkapazität – das sind tausende Server-Racks.

Strom

Rechenzentren werden 2026 voraussichtlich 1.050 Terawattstunden Strom verbrauchen – mehr als ganz Japan. Stromkosten allein machen Inferenz teuer.

Training

OpenAI plant für 2028 allein \$121 Mrd. Compute-Kosten. Ein Top-Modell zu trainieren kostet hunderte Millionen \$.

Inferenz

Jede deiner Anfragen kostet Rechenleistung. Lange Kontexte (1 Mio. Token) explodieren in den Kosten – quadratisches Wachstum.

Speicher (RAM)

HBM-Speicher ist knapp. Memory-Preise stiegen Q1 2026 um ~90 %. Datenzentren machen bereits 70 % der weltweiten Memory-Nachfrage aus.

Talente

ML-Engineers verdienen \$300.000–\$1 Mio. pro Jahr. Anthropic und OpenAI bieten sich gegenseitig die Talente weg.

Politik: Der Chip-Krieg

USA, China und die Frage, wer Rechenleistung kontrolliert

US USA

Strategie:

Compute-Vorsprung sichern, China zurückhalten, eigene Industrie subventionieren (CHIPS Act, Stargate-Projekt)

Trump 2026:

25 % Zoll auf importierte KI-Chips (Jan. 2026). H200-Verkauf an China nur, wenn 25 % an USA gehen.

Konflikt:

Republikaner streiten: China-Hardliner vs. Trump, der Geschäfte mit Nvidia & Peking macht.

CN China

Strategie:

Selbstständigkeit bei Chips bis 2030. Huawei Ascend, CXMT, YMTC sollen Nvidia, Samsung & Co. ersetzen.

April 2026:

China bringt 'Regulations on Industrial Chain Security' raus – eigene Exportkontrollen als Druckmittel.

DeepSeek-Effekt:

Trotz Sanktionen schließen chinesische Modelle die Qualitätslücke. Algorithmen schlagen Hardware.

EU EU

Strategie:

Regulieren statt bauen: AI Act (10^{25} FLOPs-Schwelle), Datenschutz, Sicherheitsprüfungen.

Sovereignty-Push:

Mai 2026: Plan, Datenzentrumskapazität in 7 Jahren zu verdreifachen. Mistral als europäische Hoffnung.

Realität:

Kauft im großen Stil US-Chips, um Trump-Zöllen zu entgehen. Abhängigkeit bleibt.

Wer kauft die Rechenleistung?

Vier Konzerne dominieren – wie früher das Erdöl

Microsoft

+ OpenAI

\$13 Mrd. Investment in OpenAI, Azure als Compute-Backbone.
Verdient an JEDER ChatGPT-Anfrage.

Amazon

+ Anthropic

Mehrere Milliarden in Anthropic. Bedrock = Anthropic's Cloud-Backbone. Trainium-eigene KI-Chips im Aufbau.

Google

+ Gemini

Eigenes Modell, eigene TPU-Chips. Vertical integriert – am wenigsten abhängig.

Meta

+ Llama

Open-Source-Strategie als Disruptor. \$100 Mrd. Capex 2026, eigene KI-Chips ('MTIA').

Wer nimmt was ein?

Run-Rate-Umsätze vs. Verluste – Stand April/Mai 2026

Anbieter	Umsatz (Run-Rate)	Verlust 2026	Bewertung	Profitabel ab
Anthropic	\$30 Mrd. ↑↑↑	ca. \$9 Mrd.	~\$1 Billion	2027
OpenAI	\$24 Mrd. ↑	\$14 Mrd.	\$852 Mrd.	2029-2030
Microsoft (Copilot)	versteckt in Cloud	profitabel	\$3,5 Billionen	längst
Google (Gemini)	versteckt in Search	profitabel	\$2,2 Billionen	längst
Meta (Llama)	\$0 direkt	Capex \$125-145 Mrd.	\$1,5 Billionen	Werbung trägt
Perplexity	\$450 Mio.	unbekannt	\$20 Mrd.	unklar
Nvidia (Hardware)	ca. \$140 Mrd./Jahr	GEWINN ~\$80 Mrd.	\$3,3 Billionen	lange profitabel

Die Pointe: Anthropic und OpenAI verbrennen JEDEN Dollar Umsatz noch in den Verlust. Microsoft, Google, Meta sind insgesamt profitabel – aber NICHT wegen KI, sondern trotz KI. Nur Nvidia verdient an KI wirklich Geld.

Wer holt das meiste aus seinen Nutzern?

Monatlicher Umsatz pro aktivem Nutzer (ARPU) – Q1 2026, Counterpoint Research



Was zählt: Nicht wer die meisten Nutzer hat, sondern wer pro Nutzer am meisten verdient. Anthropic hat 7x weniger Nutzer als OpenAI – verdient aber pro Nutzer 7x mehr. Meta sammelt Milliarden Nutzer – verdient pro Kopf 10 Cent.

Der eigentliche Gewinner

Während alle anderen Verluste machen, verdient EINER richtig viel

NVIDIA

Der Schaufel-Verkäufer im Gold-Rausch

~75 %

Marktanteil bei KI-
Beschleunigern

\$30 Tsd.

Verkaufspreis einer
H200-GPU

#1

Zeitweise wertvollster
Konzern der Welt

Egal welche KI gewinnt – Nvidia verkauft allen die GPUs. OpenAI, Anthropic, Google, Meta, xAI, jedes Forschungslabor, jede Regierung. Das ist die wahre Machtposition im KI-Markt.

Was kommt auf uns zu?

Drei realistische Szenarien für 2027–2030

Szenario 1

Preis-Explosion

wahrscheinlich

VC-Geld läuft aus, Konsolidierung beginnt. ChatGPT Plus geht von \$20 auf \$40–60. API-Preise verdoppeln sich. Gratis-Tiers werden stark gekürzt oder verschwinden.

Erkennen wirst du es an: Härtere Rate-Limits → kleine Preiserhöhungen → 'Premium-Tier' wird zur Pflicht.

Szenario 2

Effizienz-Wunder

möglich

Algorithmen werden so viel effizienter, dass Inferenz 90 % billiger wird (Sparse Attention, KV-Cache-Tricks). Preise bleiben stabil, aber Modelle werden viel besser.

Erkennen wirst du es an: Längere Kontexte, schnellere Antworten, neue Premium-Modelle ersetzen alte Tiers.

Szenario 3

Zwei-Klassen-Welt

sehr wahrscheinlich

Konzerne mit eigenen GPUs (eigene Inferenz) vs. alle anderen (Hyperscaler-Miete). Open-Source-Modelle wie Llama, Mistral, DeepSeek werden Massenmarkt, Frontier-Modelle Luxus.

Erkennen wirst du es an: Schulen, Behörden, kleine Firmen nutzen lokale Modelle. Premium-KI nur für Konzerne.

Das haben wir schon gesehen

Historische Parallelen, die helfen, das Heute zu verstehen

1995–2001

Dotcom-Blase

Investoren werfen Geld auf jedes '.com'-Logo. Pets.com, Webvan – Milliarden verbrannt. Massive Überinvestition in Glasfaser.

Aber: Die Infrastruktur (Internet) blieb. Google, Amazon, eBay haben sie billig genutzt und das echte Geld verdient.

2008–2018

Cloud-Computing

AWS, Azure, GCP rangelten um Marktanteile. Massive Preiskämpfe. Heute teilen sich drei Konzerne die Welt-Server-Infrastruktur.

Cloud wurde nicht billiger – nur effizienter. Wer komplett auf einen Anbieter setzt, ist eingesperrt (Vendor Lock-In).

2009–2020

Social Media

Facebook, Twitter, Instagram waren erst kostenlos. Erst Nutzer sammeln, dann Werbung schalten, dann Reichweite verkaufen.

Heute kosten Anzeigen viel, Reichweite ohne Bezahlen kaum möglich. 'Enshittification': Service wird schlechter, Preis steigt.

Was kannst du tun?

Praktische Strategien, um nicht abhängig zu werden



Mehrere Tools nutzen

Verlass dich nicht auf einen Anbieter. Mische ChatGPT, Claude, Gemini, NotebookLM. Wenn einer teurer wird, hast du Alternativen.



Open Source im Blick

Llama, Mistral, DeepSeek werden besser. LM Studio oder Ollama lassen Modelle lokal laufen. Hardware-Investition lohnt sich für Schulen/Vereine.



Auf API-Standards setzen

OpenAI-kompatible Endpoints sind die Lingua franca. Wer so baut, kann das Modell tauschen, ohne alles neu zu programmieren.



Daten exportierbar halten

Keine sensiblen Sachen in Custom GPTs einsperren. Eigene Daten als Markdown/Docs außerhalb der Plattformen pflegen.



Pro-Tier nicht zu früh

Free-Tier reicht für viele Aufgaben. Bezahl erst, wenn du das Limit WIRKLICH spürst und ein konkreter Workflow davon abhängt.



Jährlich neu prüfen

Der Markt verschiebt sich rasend schnell. Was heute teuer ist, kann morgen halb so viel kosten – oder doppelt so viel.

K e r n b o t s c h a f t

Heutige Preise sind nicht echt

Du nutzt eine subventionierte Demo, finanziert von Wagniskapital.

Kurzfristig

Preise dürften steigen – die Frage ist nur, wie und wann das Subventionspiel kippt.

Mittelfristig

Open-Source-Modelle werden konkurrenzfähig. Wer sich nicht anbindet, hat mehr Optionen.

Langfristig

Wer Compute kontrolliert, kontrolliert KI. Politik entscheidet mit – nicht nur der Markt.

Bleib wach. Bleib flexibel. Verlass dich nicht auf einen Anbieter.

Quellen & Weiterlesen (1/2)

Alle Zahlen aus dieser Präsentation – zum Nachprüfen

Verluste & Subventionen

European Business Magazine – OpenAI's \$14B-Verlust 2026

<https://europeanbusinessmagazine.com/sam-altmans-openai-is-burning-billions-most-users-pay-nothing-as-anthropic-closes-in/>

SaaStr – Anthropic überholt OpenAI bei Umsatz

<https://www.saastr.com/anthropic-just-passed-openai-in-revenue-while-spending-4x-less-to-train-their-models/>

Blaze Media – AI Bubble & subscription lie

<https://www.theblaze.com/return/the-ai-bubble-is-about-to-pop-here-s-how-to-prepare-yourself>

Uncover Alpha – Ende der subventionierten Modelle

<https://www.uncoveralpha.com/p/the-era-of-subsidized-ai-model-usage>

Inferenz-Kosten & Markt

AI Automation Global – Inference Cost Crisis 2026

<https://aiautomationglobal.com/blog/ai-inference-cost-crisis-openai-economics-2026>

Fortune – Nvidia exec on AI costing more than humans

<https://fortune.com/2026/04/28/nvidia-executive-cost-of-ai-is-greater-than-cost-of-employees/>

Axios – AI now costs more than human workers

<https://www.axios.com/2026/04/26/ai-cost-human-workers>

Zylo – AI Pricing Volatility 2026

<https://zylo.com/blog/ai-cost>

Quellen & Weiterlesen (2/2)

Politik, Chips, geopolitischer Kontext

Politik & Chip-Exportkontrollen

Chatham House – Export Controls als Bargaining Chip

<https://www.chathamhouse.org/2026/04/ai-export-controls-are-not-best-bargaining-chip>

CSIS – Transatlantische Export-Kontrollen

<https://www.csis.org/analysis/new-momentum-old-problems-transatlantic-export-control-considerations>

Mayer Brown – Trumps 25%-Tarif auf KI-Chips

<https://www.mayerbrown.com/en/insights/publications/2026/01/administration-policies-on-advanced-ai-chips-codified>

The Hill – 5 key AI fights in 2026

<https://thehill.com/policy/technology/5657624-5-key-ai-fights-to-watch-in-2026/>

Atlantic Council – Transatlantic AI cooperation

<https://www.atlanticcouncil.org/in-depth-research-reports/issue-brief/transatlantic-cooperation-on-ai-and-national-security/>

AI Frontiers – Wie wirken Export-Kontrollen?

<https://ai-frontiers.org/articles/us-chip-export-controls-china-ai>

Markt-Daten & Bewertungen

Tech-Insider – Anthropic vs OpenAI 2026

<https://tech-insider.org/anthropic-vs-openai-2026/>

Cybernews – OpenAI verbrennt, Anthropic profitabel

<https://cybernews.com/ai-news/openai-anthropic-profit-revenue-ai/>

CSIS – Export Controls als Industriepolitik-Hebel

<https://www.csis.org/blogs/perspectives-innovation/export-controls-national-security-tool-or-industrial-policy-lever>

Transparenz, Haftung & Datenschutz

ERSTELLUNG

Struktur und Prompt-Ideen: **DI Theodor Kranz, BSc BEd**. Recherche und Ausarbeitung erfolgten im Mai 2026 mithilfe der KI Claude Opus 4.7 (Anthropic) und wurden anschließend durch eine menschliche Kontrolle („Human in the Loop“) geprüft.

KEINE GEWÄHR

Trotz sorgfältiger Prüfung kann keine Gewähr für Richtigkeit, Vollständigkeit und Aktualität der Inhalte und Quellen übernommen werden. KI-Sprachmodelle erzeugen sprachlich plausible, logisch wirkende Antworten – nicht zwingend faktisch korrekte. Sie können Inhalte und Quellen „halluzinieren“ (überzeugend, aber falsch oder nicht existent). Bitte Inhalte und besonders Quellenangaben vor einer Weiterverwendung selbst prüfen.

DSGVO: technisch möglich ≠ erlaubt

Klausuren mit KI zu korrigieren ist technisch möglich – aber das Hochladen von Handschrift, Namen oder personenbezogenen Daten in KI-Tools ist datenschutzrechtlich heikel.

Bitte beachten:

- ✓ Personenbezug entfernen / anonymisieren (Namen, Klasse, Handschrift)
- ✓ Schulkonto / freigegebene Tools nutzen, nicht private Accounts
- ✗ Keine Schüler:innen-Daten in nicht freigegebene KI-Tools hochladen
- ✗ Keine sensiblen Daten (Gesundheit, Religion, Herkunft) verarbeiten

→ Details in der Präsentation „KI & DSGVO an Schulen“ (SCHILF, HTL1 Klagenfurt).